

NGƯỜI DÙNG / TRUY VẤN TIẾNG VIỆT (USER QUERY)

"Kiểm tra phạt nguội cho xe máy biển số 59P1-12345 tại TP. Hồ Chí Minh"

Danh mục công cụ: [tra_cuu_phat_nguoi, dat_ve_xe_khach, thanh_toan_tien_dien, ...]

PHƯƠNG PHÁP 1: SLM END-TO-END (Qwen3.5 2B/4B)

Định dạng Prompt & JSON Schema



Qwen3.5 + QLoRA SFT
(Học loss chỉ trên Assistant response)



Giải mã tự hồi quy (Autoregressive)
Sinh cấu trúc XML native: <tool_call>



JSON Tool Call Output
Arguments trích xuất trực tiếp

PHƯƠNG PHÁP 2: BI-ENCODER + CROSS-ENCODER

Bi-Encoder BGE-M3 (CachedMNRL)
Truy hồi Top-K công cụ ứng viên ($k \leq 3$)



Đầu quyết định No-call / Selection
Ngưỡng hiệu chuẩn $\tau = 0.35$, $\delta = 0.21$



Cross-Encoder XLM-R (Hierarchical Heads)
• has_value • Span head • Enum/Bool head



Value Normalizer + JSON Validator
Ảnh xạ thực thể Việt & Chuẩn hóa JSON